
Tüdőgyulladás eredetének megállapítása mellkas röntgen képek alapján

Kis Máté Levente
Budapesti Műszaki és
Gazdaságtudományi
Egyetem
mkis@edu.bme.hu

Réfi Nándor
Budapesti Műszaki és
Gazdaságtudományi
Egyetem
refinandor@edu.bme.hu

Szócska Miklós Bendegúz
Budapesti Műszaki és
Gazdaságtudományi
Egyetem
miklosbendeguzszocska@edu.bme.hu

Összefoglaló

A 2019. december 31-én megjelent COVID-19 vírus világszerte nagy kihívások elé állítja az országok egészségügyi szerveit és annak alkalmazottait. Nő az igény a betegek gyors és pontos diagnosztizálására, valamint fontos a vírus okozta tünetek kiismerése. A betegség egyik gyakori tünete a tüdőgyulladás, amelyet nem csak vírusok, de gyakran baktériumok vagy gombák is okozhatnak. A különböző típusú tüdőgyulladások felismerése kihívást jelenthet vagy időigényes lehet. Úgy gondoljuk érdemes olyan Deep Learning modellek kifejlesztésére törekedni, amelyek képesek azonosítani a tüdőgyulladás eredetét egy mellkas röntgen alapján. Az általunk létrehozott modellel három kategóriába eső képeket vizsgálunk: COVID-19 eredetű tüdőgyulladás, bakteriális eredetű tüdőgyulladás és tüdőgyulladás mentes röntgen kép. A modellhez tartozó forráskód az alábbi linken érhető el:

https://github.com/SonOf1998/COVID-19_detection_in_lungs

1 Bevezető

1.1 Motiváció

1.2 Megelőző hasonló projektek

2 Adatelőkészítés

2.1 Felhasznált adatbázisok

2.2 Training-Validation-Test felosztás

2.2 Augmentálás

3 Probléma megközelítése

3.1 Eddig kipróbált modellek

3.2 SE-ResNet152 hálózat

3.3 Felső Dense rétegek



4 Tanítás és kiértékelés

Több tanítást is lefuttattunk és kísérletezéssel próbáltuk elérni a lehető legjobb eredményeket. Több optimalizációs algoritmust, aktivációt is kipróbáltunk. Változtattuk a neuronok számát és dropout rétegeket vezettünk be, valamint hiperparaméterek optimalizására szánt könyvtárakat kihasználva finomítottuk tovább a modellünket.

4.1 Tanítás menete

A tanítások során azt véltük felfedezni, hogy a legjobb eredményeket úgy érjük el, ha a SE-ResNet152 modell rétegeit is tovább tanítjuk az erre épített dense modellünkkel együtt. Végül a SE Resnet152 felső 914 rétegből csak 698-ot tudtunk tovább tanítani, mivel az elérhető grafikus kártyáink memóriája csak erre volt elég.

A modellhez kipróbáltuk mind az Adam^[1], SGD^[2] és AdaBound^[3] optimalizációs algoritmusokat, melyek közül az AdaBound bizonyult a leggyorsabb és legnagyobb accuracy-t biztosító algoritmusnak.

Checkpointing módszert használtunk, hogy tanítás végén a modell legjobb állapotát értékeljük ki, valamint Early Stopping-ot, hogy overfitting esetén leállítsuk a tanítást. A tanítás folyamatát logoljuk, amelyet később Tensorboardon jelenítettünk meg.

4.2 Hiperparaméter optimalizálás


A top dense rétegek neuronszámát és a dense rétegek közötti dropout rétegek rate-jét optimalizáltuk a Keras-Tuner random search algoritmusát alkalmazva. Az algoritmust 20 iterációig futtattuk, amelyek közül a legjobb validation accuracy-val bíró hiperparaméterek együttesét választottuk.

5 Eredmények vizualizálása

Az eredmények vizuális ábrázolása sokat segíthet a modell javításában és az eredmények értelmezésében, így mi is több technikát alkalmaztunk ilyen célokra.


5.1 Konfúziós mátrix

Az egyik legismertebb technika az úgynevezett konfúziós mátrix, ebből azt olvashatjuk le hogy melyik osztályokat milyen osztálynak tippelte a modell, és így következtethetünk rá melyik képekkel van problémája a modellnek és esetleg hol tudunk javítani rajta.



Egyértelműen látszik hogy míg a covid-os képeket közel tökéletesen felismeri, a pneumóniás és egészséges képek felismerésével nehézségei vannak.

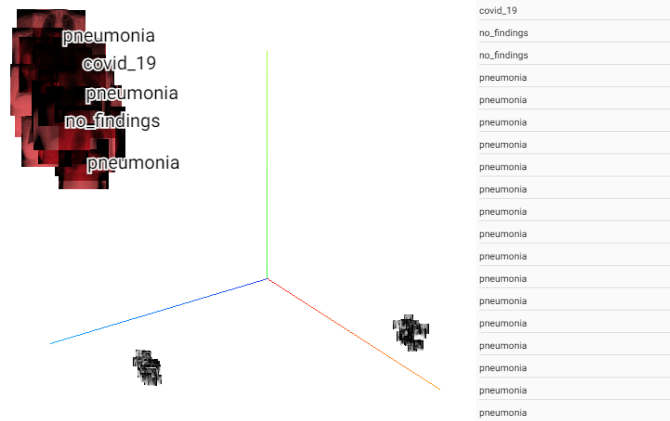
5.2 TensorBoard - Tanítás



Az ábrákon a tanítás alatt epoch-onként logolt pontosság és hiba értéke látható. A narancssárga vonalak a tanítás eredményei, a kékek a validációé. Látszik hogy a modell gyorsan tanul és beáll egy kő értékre, azonban ennél még lehetnének jobb eredményei is további fejlesztések árán. A vége felé, a 18 epoch környékén, túltanulás jelei is megfigyelhetők, de ez ellen védett, hogy a legjobb validációs pontosságot produkáló modell súlyait mindig mentettük.

5.3 TensorBoard – Projection

Használtunk projekciót is az utolsó konvolúciós réteg kimenetelén. Lényegében predikáltunk a teszt képeken, és az utolsó konvolúciós réteg kimenetelét embedding-e alakítva, azokon futtatunk egy dimenzió csökkentő algoritmust, hogy így 3D-ben tudjuk megjeleníteni. Azt vizsgáltuk, hogy mennyire alkotnak csoportokat a kimenetek, és azok mennyire különülnek el egymástól.



A két képen egy UMAP algoritmust használó futás eredménye látható. Jól elkülöníthető csoportok képződnek, és a kijelölt csoportban található képek osztályait vizsgálva, (amelyek a jobb oldali képen láthatóak,) azt látjuk, hogy nagyrészt azonos osztályba tartozó képek kerültek egy csoportba, így a modellünk jól elkülöníti őket.

5.4 GradCAM

Egy olyan módszer ami azon alapszik, hogy az utolsó konvolúciós réteg aktivációit vizsgáljuk és deriválással visszafejtjük. Lényegében egy olyan hőképet nyerhetünk ki képekhez, amik azt mutatják meg, az egyes tartományai mennyiben járultak hozzá a modell legnagyobb valószínűségű predikciójához. Leegyszerűsítve azt vizsgáljuk, miért azt tippelte a modell, amit, így ellenőrizve, hogy a megfelelő problémát oldja-e meg.



Két kép látható, melyekre helyes predikció született. Az alsó sarokban látható a (helyes) osztály és a hozzá tartozó valószínűség. Arra tudunk következtetni a képekből, hogy a modell valóban a tüdőben fellelhető mintázatokat vizsgálja és az alapján dönt, ami siker. Azonban látható, hogy a váll környékét is vizsgálja ahol felirat látható sok képen, így időnként hibázik is szemantikai értelemben, mert a feliratnak nincs köze a betegségekhez. (Ha mégis van köze a feliratnak a betegséghez egyes esetekben, az még rosszabb lehet, mert olyan információt használ amit nem lenne szabad.)

6 Konklúzió

Referenciák

- [1] Diederik P. Kingma & Jimmy Lei Ba. Adam (2015) A method for stochastic optimization, *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*
- [2] Herbert Robbins & Sutton Monro (1951) A stochastic approximation method, *The Annals of Mathematical Statistics*, 22(3):400-407
- [3] Liangchen Luo, Yuanhao Xiong, Yan Liu & Xu Sun (2019) Adaptive Gradient Methods with Dynamic Bound of Learning Rate, *International Conference on Learning Representations (ICLR) 2019 Conference*